Brecha Digital y Rendimiento Escolar en el Perú

Análisis mediante Machine Learning y XAI utilizando Microdatos ENAHO y ESCALE 2025

Autor: Puma Condori Julmer | **Curso:** Inteligencia Artificial | **Fecha:** Octubre 2026

1. Introducción y Planteamiento del Problema

El cierre de la brecha digital y la evaluación de su impacto en la Educación Básica Regular peruana requieren metodologías que trasciendan la estadística descriptiva tradicional. A pesar de los esfuerzos estatales, las disparidades de infraestructura tecnológica y condiciones socioeconómicas persisten, especialmente en las zonas rurales, altoandinas y amazónicas. Este proyecto aborda la exclusión tecnológica estudiantil modelando la complejidad de estas asimetrías mediante algoritmos de Inteligencia Artificial.

El problema central radica en identificar qué combinación de factores socioeconómicos, educativos y geográficos empujan a un estudiante hacia la exclusión digital efectiva. Resolver esta interrogante no solo permite perfilar las tipologías de vulnerabilidad en el territorio nacional, sino que proporciona evidencia empírica clave para la focalización y priorización de políticas públicas, optimizando la asignación de recursos educativos y de conectividad.

2. Objetivos del Proyecto

El **Objetivo General** es desarrollar, validar e interpretar un *pipeline* integral de *Machine Learning* (No Supervisado y Supervisado) fusionando los microdatos de ENAHO 2025 y ESCALE 2025 para perfilar la brecha digital estudiantil y predecir el riesgo de exclusión tecnológica en el Perú.

Los **Objetivos Específicos** abarcan:

- Efectuar ingeniería de datos y cruces relacionales estrictos entre hogares (INEI) y distritos educativos (MINEDU).
- Identificar perfiles de vulnerabilidad y privilegio mediante algoritmos de *Clustering*.
- Entrenar clasificadores avanzados previniendo estrictamente la fuga de datos espacial (*Data Leakage*).
- Auditar la explicabilidad del modelo final mediante la teoría de juegos (valores SHAP).

3. Fuentes y Arquitectura de Datos

Se integraron dos repositorios oficiales de microdatos estatales **[1]**:

- **INEI (ENAHO 2025):** Módulos 100 (Vivienda), 200 (Miembros del Hogar), 300 (Educación) y Sumaria. Se aisló a la población en edad escolar estricta (6 a 17 años).
- **MINEDU (ESCALE 2025):** Padrón de Instituciones Educativas (DBF), desde el cual se calcularon indicadores agregados a nivel distrital, como el ratio de saturación (Total Alumnos / Total Docentes).

4. Metodología e Ingeniería de Datos

La ingesta de datos enfrentó las trampas clásicas de los microdatos estatales. Para prevenir la pérdida de geocódigos, llaves primarias como `UBIGEO`, `CONGLOME` y `CODPERSO` fueron procesadas garantizando sus ceros a la izquierda, y las celdas en blanco fueron tratadas sistemáticamente como valores nulos. El cruce relacional (*Left Join*) unificó la información del estudiante con la de su hogar y su respectivo entorno educativo distrital.

> **Estrategia Anti Fuga de Datos (Zero Data Leakage):** En la fase de validación, la partición de los datos en entrenamiento y prueba se ejecutó obligatoriamente utilizando `GroupKFold` aglutinando por `CONGLOME`. Esto garantizó que miembros del mismo hogar o vecindario encuestado no contaminaran simultáneamente los conjuntos de entrenamiento y evaluación.

5. Resultados: Modelado No Supervisado (Clustering)

Para descubrir perfiles latentes sin etiquetas previas, se aplicó un algoritmo K-Means tras escalar las variables socioeconómicas y educativas. Evaluando métricas internas de cohesión como el Índice de Davies-Bouldin (0.880) y Calinski-Harabasz (16,037), la configuración matemática convergió óptimamente en 3 clústeres. La caracterización revela una radiografía profunda de la desigualdad:

Perfil (Clúster)	Ingreso Anual (S/.)	Gasto Anual (S/.)	Ratio Alumno/Docente	Interpretación Sociodemográfica
0 (Vulnerabilidad)	25,441	22,398	10.6	Zona rural de extrema pobreza, escuelas despobladas y unidocentes.
2 (Clase Media)	37,521	32,313	17.3	Urbanidad periférica emergente con escuelas públicas de alta saturación.
1 (Privilegio)	106,595	78,388	16.8	Alto poder adquisitivo, educación privada e infraestructura óptima.

El bajo ratio alumno/docente en el Clúster 0 no representa una ventaja pedagógica, sino que evidencia el aislamiento de los centros poblados rurales (escuelas multigrado y unidocentes con bajísima matrícula) **[2]**.

6. Resultados: Clasificación Supervisada

El problema supervisado se definió como la predicción binaria de la exclusión digital del estudiante (`TARGET = 1` si no accedió a internet en los últimos 3 meses, obtenido de la variable `P314A`). Utilizando 23,668 registros limpios, se empleó como variables predictoras el ingreso, gasto, edad (`P208A`), ratio docente distrital, estrato geográfico y una variable de lengua originaria (`P300A` derivado).

Debido al desbalance de clases nativo de la ENAHO, se utilizó la técnica de penalización `class_weight='balanced'`. Se contrastó un algoritmo de línea base (Regresión Logística) frente a un algoritmo avanzado basado en árboles (LightGBM).

RENDIMIENTO GLOBAL (ROC-AUC)	SENSIBILIDAD (RECALL - EXCLUIDOS)	PRECISIÓN (CLASE MINORITARIA)
0.810	**81.0%**	**57.0%**

Ambos algoritmos empataron en su área bajo la curva (0.810), demostrando que las fronteras de decisión sociológicas son marcadas y predecibles geométricamente. Sin embargo, el comportamiento interno del LightGBM es altamente valioso para la gestión pública: su Recall del 81% garantiza la identificación exitosa de 8 de cada 10 escolares desconectados. El sacrificio de precisión (existen falsos positivos) es el costo teórico aceptable de priorizar cobertura sobre exactitud en un programa social **[3]**.

7. Explicabilidad Algorítmica (XAI - SHAP)

Para desopacar el ensamblaje de árboles, se auditaron las decisiones individuales y globales del algoritmo LightGBM utilizando los valores de Shapley (SHAP). El gráfico tipo enjambre (*Beeswarm*) extraído durante la ejecución evidenció contundentemente que los determinantes tecnológicos están supeditados a la barrera etaria y territorial.

Las variables con mayor empuje marginal hacia la exclusión digital fueron: una edad temprana (niños menores empujados por valores bajos de `P208A`), residir en áreas rurales (altos valores en `ESTRATO`) y poseer ingresos precarios (bajos valores de `INGHOG2D`). Al aislar predicciones extremas mediante gráficos *Waterfall*, se constató que un niño de 7 años en extrema pobreza posee casi un 90% de riesgo absoluto de desconexión, empujado por más de 1.4 puntos lógit exclusivamente por su edad y entorno, mientras que un adolescente de 17 años con ingresos superiores al promedio obtiene un factor protector contundente frente a la desconexión.

8. Conclusiones y Recomendaciones

El modelado demuestra matemáticamente que la brecha digital peruana en etapa escolar no es una variable aleatoria, sino un constructo rígido altamente predecible (AUC > 80%) originado por la segregación geográfica y económica. El algoritmo K-Means comprobó que los colegios con menores ratios de hacinamiento paradójicamente pertenecen a zonas rurales de pobreza crónica.

Se recomienda utilizar el modelo LightGBM desarrollado como motor de *scoring* y focalización preliminar para el despliegue de políticas estatales (como el programa Pronatel), ya que prioriza el descubrimiento del estudiante vulnerable (alta sensibilidad) y justifica sus designaciones mediante perfiles explicables y rastreables (SHAP).

9. Limitaciones del Estudio

El estudio enfrenta ciertas limitaciones de disponibilidad. En primer lugar, la capacidad predictiva sobre variables puramente educativas (como el desempeño cognitivo directo) carece de asidero dado que la ENAHO no aplica pruebas estandarizadas (como la ECE del MINEDU, cuyos microdatos no se cruzan a nivel individual por anonimato). En segundo lugar, los modelos elaborados miden correlación y capacidad discriminante de estados de vulnerabilidad, lo cual no debe confundirse matemáticamente con causalidad estricta entre la infraestructura y el rendimiento.

10. Referencias Bibliográficas

[1] Instituto Nacional de Estadística e Informática (INEI) & MINEDU. (2025). *Microdatos ENAHO (Módulos 100-300 y Sumaria) y Censo Educativo ESCALE*.

[2] Ministerio de Educación del Perú. (2024). *Estadística de la Calidad Educativa (ESCALE): Glosario de Indicadores de Infraestructura Escolar*.

[3] Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.